

The social network

Soutenance du projet de Simulations et MonteCarlo

Pierre Delanoue - Clément Guillo - Hugues Gallier

ENSAE ParisTech

21 mai 2019

- 1 Simulation par MCMC
 - Gibbs sampling
 - Convergence et indépendance

- 2 Estimation des paramètres
 - Important sampling
 - EMV : descente de gradient

- 3 Perspectives

Introduction

- Objectif 1 : Simuler un réseau modélisé par un Exponential Random Graph Model (ERGM)
- Objectif 2 : À partir d'un réseau donné, le caractériser à partir des coefficients estimés du modèle

- 1 Simulation par MCMC
 - Gibbs sampling
 - Convergence et indépendance
- 2 Estimation des paramètres
 - Important sampling
 - EMV : descente de gradient
- 3 Perspectives

Gibbs Sampling

- Réseaux de n noeuds, on modélise ses liens par :
 $x_{ij} = 1$ si i et j sont reliés, 0 sinon
- Représentation matricielle $X \in \mathcal{M}(\{0, 1\}^{n \times n})$
- Loi jointe des $X_{i,j}$ est $p(x|\theta) = \frac{1}{Z(\theta)} \exp^{\theta^T S(x)}$
- $S(x) = [\sum_{i < j} x_{ij}, \sum_{i < j < k} x_{ij} x_{jk} x_{ki}]$ et $Z(\cdot)$ inconnu.

Gibbs Sampling

- On remplace tour à tour x_{ij} par la réalisation d'une Bernoulli de paramètre :


$$P(X_{ij} = 1 | \theta, x_{-ij}) = \frac{1}{1 + \exp^{\theta^T (S_0(x) - S_1(x))}}$$

- $S_1(x)$, statistique de la matrice x où x_{ij} vaut 1, $S_0(x)$ la même chose pour x_{ij} valant 0.
- Seulement besoin de calculer les statistiques d'une matrice



Convergence

- $M_1 \dots M_n$, générations issues du Gibbs sampling
- Chaîne de Markov à espace d'états fini, irréductible :
récurrente positive
- Théorème ergodique : $\sum_{i=1}^n S(M_i) \longrightarrow \mathbb{E}_{p(x|\theta)}(S(X))$
- Combien d'itérations suffisent pour converger ?

Théorème ergodique





Convergence de la loi



Pseudo Indépendance


- Calcul des autocorrélations $\gamma(h)$ à différent ordres h
- Recherche de l'ordre h tel que $\gamma(h) \approx 0$

Pseudo Indépendance



- Test et Corrélation de Spearman

Estimateur de Monte Carlo



- 1 Simulation par MCMC
 - Gibbs sampling
 - Convergence et indépendance
- 2 Estimation des paramètres
 - Important sampling
 - EMV : descente de gradient
- 3 Perspectives

Importance sampling

On part de notre équation :

$$\begin{aligned} 1 &= \mathbb{E}_{\theta_0} \left(\frac{f_{\theta}(X)}{f_{\theta_0}(X)} \right) \\ &= \mathbb{E}_{\theta_0} \left(\frac{Z(\theta_0)}{Z(\theta)} \exp^{(\theta - \theta_0)S(X)} \right) \end{aligned}$$

Donc :

$$Z(\theta) = Z(\theta_0) \mathbb{E}_{\theta_0} \exp^{(\theta - \theta_0)S(X)}$$

Ainsi :

$$L(x, \theta) \propto \frac{1}{\mathbb{E}_{\theta_0}(\exp^{(\theta - \theta_0)S(X)})} \exp^{\theta S(x)}$$

Important sampling

On maximise donc :

$$l(x, \theta) \propto -\log(\mathbb{E}_{\theta_0}(\exp^{(\theta-\theta_0)S(X)}) + \theta S(x)$$

$$\propto \theta S(x) - \log\left(\frac{1}{N} \sum_{i=1}^N \exp^{(\theta-\theta_0)S(X_i)}\right)$$

$$\propto \theta S(x) - \log\left(\exp^{(\theta-\theta_0)S(X_m)} \frac{1}{N} \sum_{i=1}^N \exp^{(\theta-\theta_0)*(S(X_i)-S(X_m))}\right)$$

$$\propto \theta S(x) - (\theta - \theta_0)S(X_m) - \log\left(\frac{1}{N} \sum_{i=1}^N \exp^{(\theta-\theta_0)*(S(X_i)-S(X_m))}\right)$$

Descente de gradient

- $\ln\left(\frac{Z(\theta)}{Z(\theta_0)}\right)$ estimé par importance sampling
- Recherche du bon estimateur par descente de gradient, avec :

$$\frac{\partial l(x, \theta)}{\partial \theta} = S(x) - S(X_m) - \frac{\frac{1}{N} \sum_{i=1}^N (S(X_i) - S(X_m)) \exp^{(\theta - \theta_0) * (S(X_i) - S(X_m))}}{\frac{1}{N} \sum_{i=1}^N \exp^{(\theta - \theta_0) * (S(X_i) - S(X_m))}}$$

- 1 Simulation par MCMC
 - Gibbs sampling
 - Convergence et indépendance
- 2 Estimation des paramètres
 - Important sampling
 - EMV : descente de gradient
- 3 Perspectives

Perspectives

- Travail généralisable à des réseaux orientés
- Développer les statistiques associées au réseau
- algorithme tie-no-tie